



**Tecnológico
de Monterrey**

Herramientas computacionales: el arte de la analítica (Gpo 201)

Actividad Evaluable: Limpieza de datos

Profesor:

Dr. Aram Baruch González Pérez

Alumno:

Juan Manuel Torres Rottonda |A01800476| ITC

Fecha de entrega:

24 de octubre de 2024

Resumen

Se limpio la base de datos de manera uniforme y rápida. Se analizo que habían muy pocos datos perdidos en ciertas columnas y se eliminaron perdiendo aproximadamente el 2% de los valores. Se volvió de objeto a float el income. Se eliminaron de 1249 a 952 entradas duplicadas, las cuales se guardaron en un .csv independiente para futuras revisiones. Se guardo el archivo limpio.

1. Introducción

El conjunto de datos es de compradores de bicicletas y se limpia para análisis estadístico.

1.1 Conjunto de Datos

Vienen: ID, Marital Status, Gender, Income, Children, Education, Occupation, Home Owner, Cars, Commute Distance, Region, Age, Purchased Bike y fueron tomados de Kaggle.com

1.2 Objetivos de la Limpieza

Se espera una normalización de los datos para un fácil análisis en código y plot

2. Exploración Inicial

La mayoría de los datos se encuentran normalizados y completos, se encontraron algunos duplicados.

3. Proceso de Limpieza

Se reviso exhaustivamente, se encontró que había pocos valores faltantes dejados en blancos en las columnas. Se eliminaron estos al ser muy pocos. Los duplicados fueron eliminados. El income fue transformado a float.

3.1 Tratamiento de Valores Faltantes

Fueron simplemente eliminados al ser muy pocos.

3.2 Corrección de Datos Erróneos

no se encontraron tales datos erróneos

3.3 Manejo de Valores Atípicos

NA

3.4 Estandarización y Normalización

NA

4. Resultados

se encontró que la base de datos se hallaba completa, sin espacios dejados en blancos y sin duplicados.

4.1 Estadísticas Descriptivas

no aplica, se encontró desde los datos numéricos.

4.2 Distribución de Datos

NA

5. Conclusiones

Ahora se puede decir con confianza que puede ser utilizado el archivo. CSV para análisis de datos,

6. Recomendaciones

Añadir mayor cantidad de fuentes de información para poder comparar o recopilar

7. Referencias

- **Python:**

- Python Software Foundation. *Python: A Programming Language*. Version 3.x. Available at: <https://www.python.org>

- **pandas:**

- McKinney, W. *pandas: Powerful data structures for data analysis in Python*. Version 1.x. Available at: <https://pandas.pydata.org>

- **Matplotlib:**

- Hunter, J. D. (2007). *Matplotlib: A 2D Graphics Environment*. Computing in Science & Engineering, 9(3), 90–95. DOI: <https://doi.org/10.1109/MCSE.2007.55>

- **seaborn:**

- Waskom, M. L. (2021). *Seaborn: statistical data visualization*. Journal of Open Source Software, 6(60), 3021. DOI: <https://doi.org/10.21105/joss.03021>

Kumar, A. (2018). *Bike buyers*. Kaggle.

<https://www.kaggle.com/datasets/anmolkumar/bikebuyers>